Compiladores

Introdução à Compilação

Prof. Edson Alves

Faculdade UnB Gama

Sumário

Histórico

- Os primeiros compiladores surgiram na década de 50
- Não há registros precisos de qual foi o primeiro compilador
- Os primeiros compiladores lidavam com a tradução de fórmulas aritméticas (FORTRAN – *Formula Translator*)
- Os compiladores eram considerados programas difíceis de se escrever
- O primeiro compilador Fortran levou 18 homens-ano para ser escrito (1 homen-ano $\approx$ 2.080 horas)
- Embora continue não sendo uma tarefa não trivial, a escrita de compiladores se beneficiou dos avanços da área desde então

Definição

Definição de compilador (informal)

Um compilador é um programa que lê um programa escrito em uma linguagem (linguagem fonte) e o traduz para uma outra linguagem (linguagem alvo).

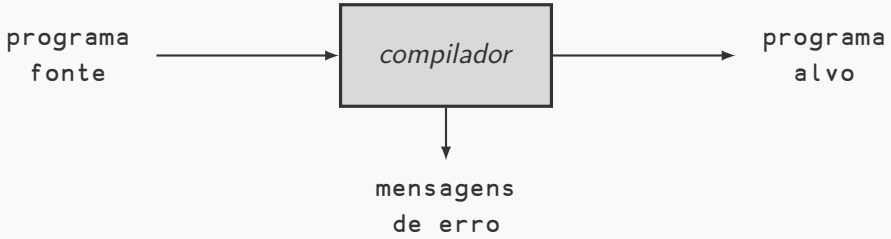

Características dos compiladores

- O processo de compilação deve identificar e relatar possíveis erros no programa fonte
- Em geral, as linguagens fonte são linguagens de programação tradicionais (C/C++, Java, Python, etc)
- As linguagens alvo podem ser tanto linguagens tradicionais quanto linguagens de máquina
- Os compiladores podem ser classificados de diversas formas, dependendo de seu objetivo ou como foi construído (de uma passagem, múltiplas passagens, depuradores, etc)

Criação do programa executável

- Além do compilador, outros programas podem ser usados na criação do programa executável
- Antes de ser passado para o compilador, o programa alvo pode ser pré-processado (por exemplo, o pré-processador da linguagem C processa as diretivas como `#include` e `#define`)
- Após a compilação, o programa alvo pode demandar processamento adicional para a construção do executável (novamente no caso da linguagem C, temos o montador e o *linkeditor*)

Exemplo de fluxo de geração de um programa executável

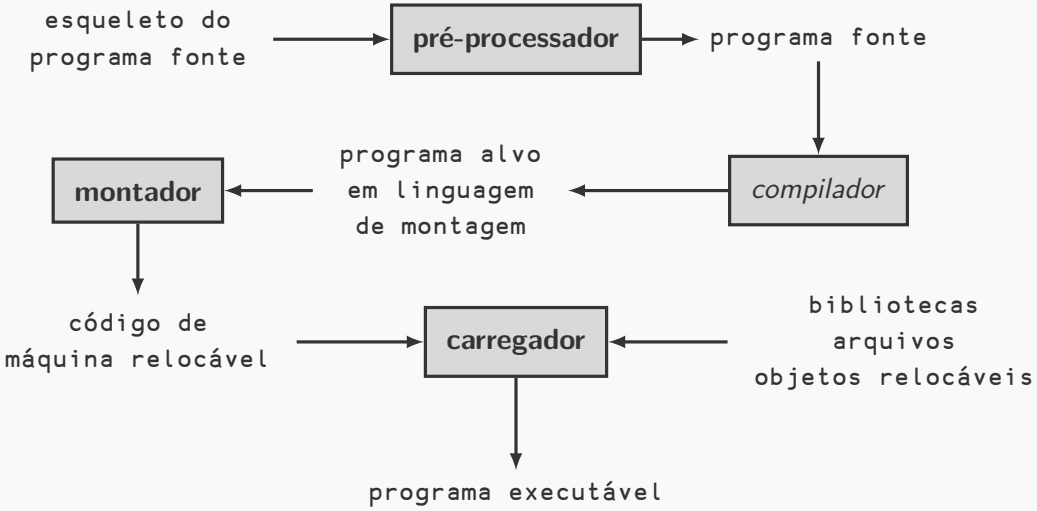

Análise e síntese

- A compilação é composta por duas partes: análise e síntese
- A análise divide o programa fonte em partes constituintes e as organiza em uma representação intermediária
- Em geral, a representação intermediária consiste em uma árvore sintática, onde cada nó representa uma operação e cada filho representa um operando
- A síntese constrói o programa alvo a partir desta representação intermediária

Exemplo de árvore sintática

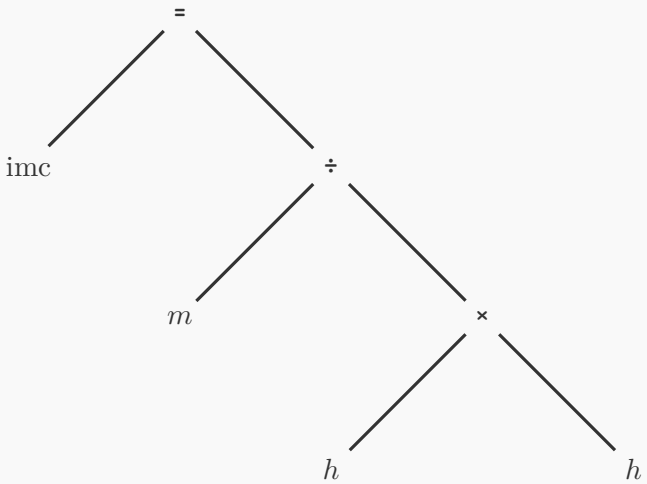

Figura: Árvore sintática da fórmula $\mathrm{imc} = m/h^2$.

Análise do programa fonte

A análise é composta por três fases:

1. *análise linear*: o fluxo de caracteres que compõem o programa alvo é lido, da esquerda para direita, e agrupado em *tokens* (sequência de caracteres com significado coletivo)
2. *análise hierárquica*: os *tokens* são ordenados hierarquicamente em coleções aninhadas com significado coletivo
3. *análise semântica*: verificação que garante que os componentes do programa se combinam de forma significativa

Análise léxica

Em um compilador, a análise linear também é denominada análise léxica ou esquadrinhamento. Por exemplo, no enunciado

```
F = 1.8 * C + 32
```

a análise léxica identificaria os seguintes *tokens*:

1. o identificador `F`
2. o símbolo de atribuição `=`
3. a constante em ponto flutuante `1.8`
4. o símbolo de multiplicação `*`
5. o identificador `C`
6. o símbolo de adição `+`
7. a constante inteira `32`

Análise sintática

A análise hierárquica também é denominada análise sintática ou gramatical. Ela agrupa os *tokens* hierarquicamente, em geral em uma árvore gramatical

A estrutura hierárquica pode ser definida por meio de regras recursivas. Por exemplo, considere as seguintes regras:

1. qualquer identificador é uma expressão
2. qualquer número é uma expressão
3. se E_1 e E_2 são expressões, também são expressões $E_1 + E_2$ e $E_1 * E_2$
4. se I é um identificador e E uma expressão, então $I = E$ é um enunciado

Exemplo de árvore gramatical

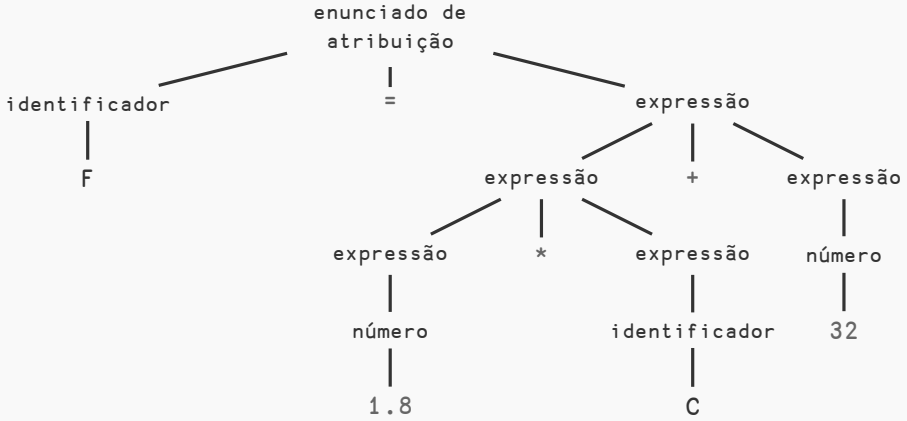

Figura: Árvore gramatical do enunciado `F = 1.8 * C + 32`

Análise semântica

- A análise semântica verifica potenciais erros semânticos no programa alvo
- Ela usa a árvore da análise sintática para identificar operadores e operandos das expressões e enunicados
- Ela também faz a verificação de tipos
- Caso os tipos dos operandos não sejam compatíveis com os tipos esperados pelos operadores, esta análise ou retorna um erro ou adiciona uma promoção (ou conversão) de tipo, a depender da linguagem alvo
- Por exemplo, na expressão à direita do enunciado `F = 1.8 * C + 32`, o operando à esquerda da soma tem tipo ponto flutuante e o da direita tipo inteiro: o valor `32` deve ser promovido para ponto flutuante ou deve ser sinalizado um erro de tipo

As fases de um compilador

- Conceitualmente, o compilador opera em fases
- Cada fase manipula o programa fonte e entrega o resultado para a próxima fase
- Na prática, algumas fases podem ser agrupadas, e a representação intermediária entre elas pode ser não se construída explicitamente
- As primeiras fases estão relacionadas à análise do programa fonte, as últimas estão relacionadas à síntese (construção do programa alvo)
- Duas atividades interagem com todas as fases: a gerência da tabela de símbolos e o tratamento de erros

Representação típica das fases de um compilador

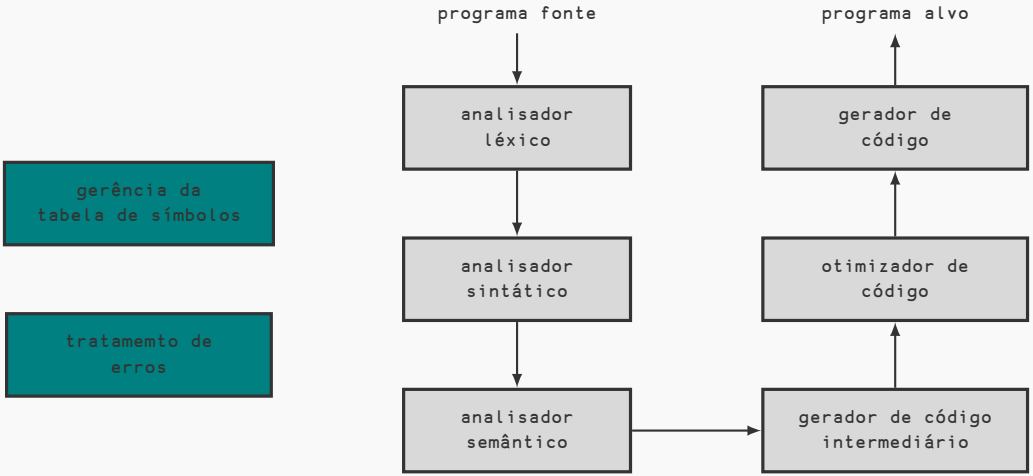

Gerenciamento da tabela de símbolos

- Esta atividade registra os identificadores do programa alvo e identifica seus diversos atributos
- Exemplos de possíveis atributos de um identificador: nome, tipo, memória e escopo
- Caso o identificador se refira a um procedimento, dentre seus atributos devem constar a quantidade de seus parâmetros e respectivos tipos, modo de passagem (cópia ou referência) e o tipo do retorno, se houver
- Os identificadores e seus respectivos atributos são armazenados em uma estrutura denominada tabela de símbolos

Tratamento de erros

- A cada fase da compilação podem acontecer um ou mais erros
- Após a identificação do erro, o compilador deve tratá-lo de alguma maneira e, se possível, continuar o processo em busca de outros erros
- Abortar a compilação logo no primeiro erro pode diminuir a utilidade do compilador (por exemplo, o prosseguimento da compilação após um erro léxico pode ajudar na geração de uma sugestão de correção para o erro)
- As análises sintática e semântica podem identificar uma parcela considerável dos erros no programa fonte

Exemplo da parte da análise do programa fonte

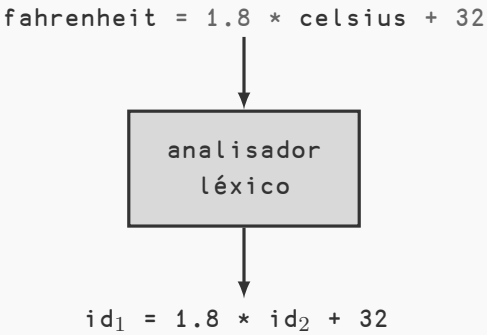

Figura: Análise léxica do enunciado `fahrenheit = 1.8 * celsius + 32`

Exemplo da parte da análise do programa fonte

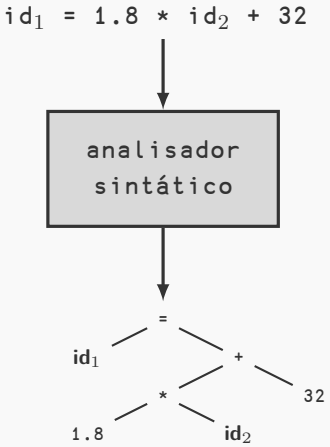

Figura: Análise sintática

Exemplo da parte da análise do programa fonte

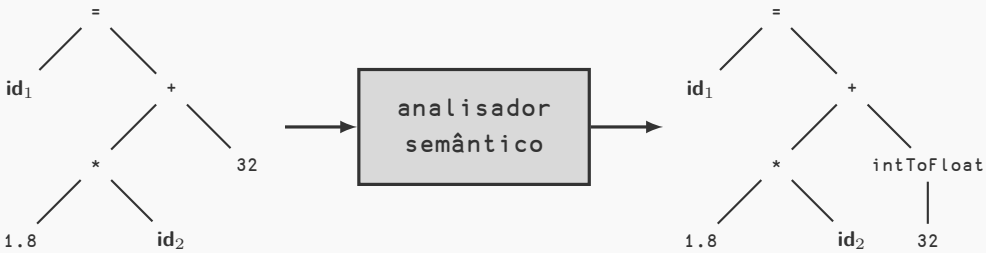

Figura: Análise semântica

Geração de código intermédiario

- A árvore resultante da análise semântica é transformada pelo compilador em um código intermediário
- Esta representação pode ser entendida como um código para uma máquina abstrata
- O código intermediário deve ter duas qualidades fundamentais:
  1. deve ser fácil de gerar
  2. deve ser fácil de traduzir para o programa alvo
- Uma representação possível é o código de três endereços
- Além de computar expressões, esta representação também precisa tratar dos fluxos de controle e das chamadas de procedimentos

Exemplo de geração de código intermediário

Figura: Representação por código de três endereços

Otimização do código

- Esta fase procura formas de melhorar o código intermediário, com o intuito de melhorar a performance do código de máquina do programa alvo
- Algumas otimizações são triviais, outras demandam algoritmos sofisticados, impactando no tempo de compilação
- As otimizações não devem alterar a semântica do código intermediário
- As otimizações podem melhorar, além do tempo de execução, o uso de memória do programa alvo

Exemplo de otimização do código intermediário

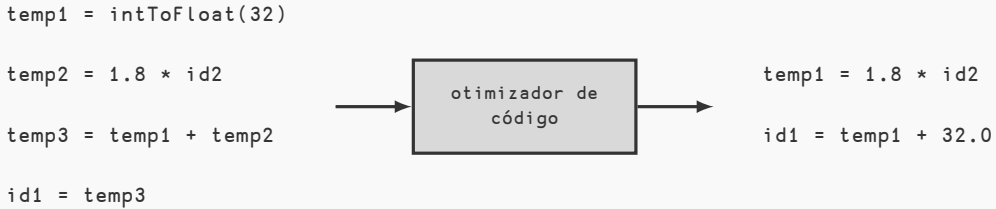

Figura: Otimização

Geração de código

- A geração de código é a última etapa da compilação
- Ela produz o programa alvo, em geral em linguagem de máquina relocável ou código de montagem
- Nesta etapa devem ser atribuídas localizações de memória para as variáveis e também feita a atribuição das variáveis aos registradores

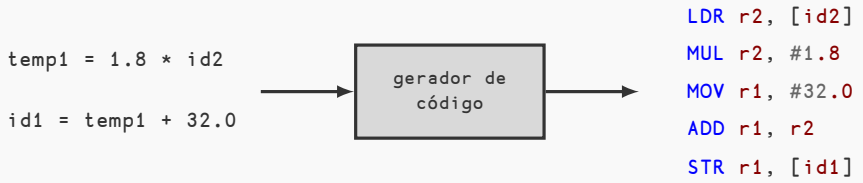

Figura: Geração de código em pseudo assembly

Interface de vanguarda

- Na práticas, as fases de um compilador são agrupadas em duas interfaces: vanguarda e retaguarda
- A interface de vanguarda contém as fases que dependem primariamente do programa fonte e que independem da máquina alvo
- Em geral, ela inclui as fases de análise, a criação da tabela de símbolos e a geração de código intermediário
- Ela também inclui o tratamento de erros associados a estas fases
- Embora a otimização faça parte primariamente da interface de retaguarda, é possível aplicar algum nível de otimização na interface de vanguarda

Interface de retaguarda

- A interface de retaguarda contém as fases que dependem primariamente da máquina alvo, e independem do programa alvo
- O ponto de partida é o código intermediário
- Assim, esta interface contém, em geral, as fases de otimização e geração de código
- Ela também manipula a tabela de símbolos e trata dos erros associados à estas últimas duas fases
- No cenário ideal, ambas interfaces são independentes, o que permite fixar uma delas e alterar a outra para obter diferentes compiladores com diferentes objetivos

Compiladores de uma mesma linguagem para múltiplas máquinas

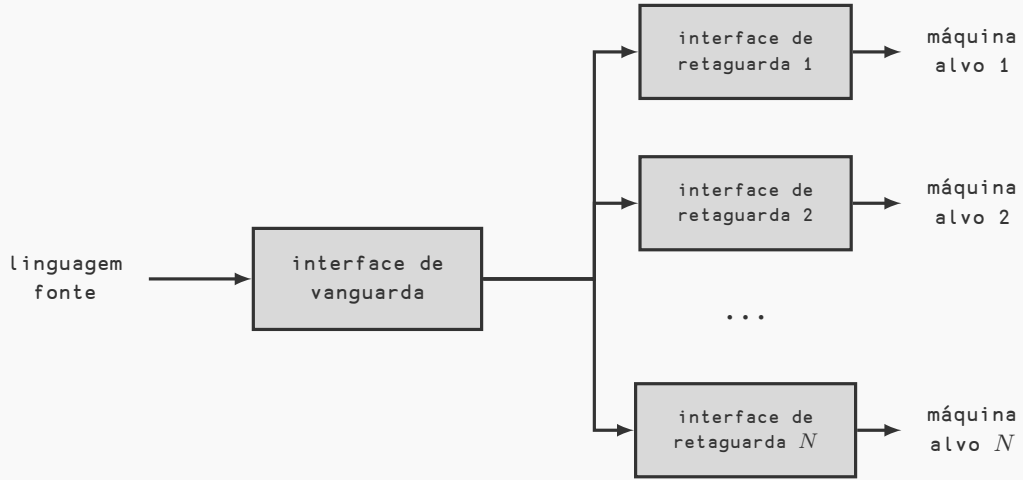

Compiladores de múltiplas linguagens para uma mesma máquina

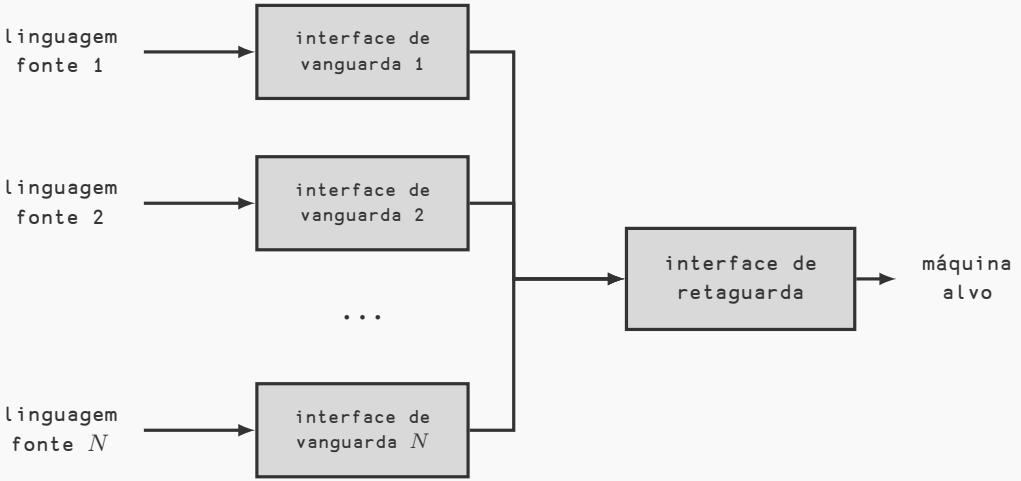

Ferramentas para a construção de compiladores

- Sendo o compilador um software, todas as ferramentas úteis no desenvolvimento de um software também serão úteis na construção de um compilador (editor de texto, depuradores, gerenciadores de versão, etc)
- Existem, entretanto, ferramentas especializadas nas diferentes fases da compilação, as quais podem ser usadas na construção de novos compiladores
- Os geradores de analisadores gramaticas produzem analisadores sintáticos a partir de uma entrada baseada em uma gramática livre de contexto (Yacc, Bison, etc)
- Os geradores de analisadores léxicos geram os mesmos a partir de especificações baseadas em expressões regulares (Lex, Flex, etc)

Ferramentas para a construção de compiladores

- Os dispositivos de tradução dirigidos pela sintaxe produzem uma coleção de rotinas que percorrem uma árvore gramatical, gerando código intermediário a partir dela
- Os geradores automáticos de código estipulam regras que traduzem cada operação da linguagem intermediária para a linguagem de máquina alvo
- Os dispositivos de fluxo de dados atuam na fase de otimização a partir da observação do fluxo de dados entre as diferentes partes de um programa

Referências

1. **AHO**, Alfred V, **SETHI**, Ravi, **ULLMAN**, Jeffrey D. *Compiladores: Princípios, Técnicas e Ferramentas*, LTC Editora, 1995.
2. GNU.org. GNU Bison, acesso em 23/05/2022.
3. Wikipédia. Flex (lexical analyser generator), acesso em 23/05/2022.